1 Cosa stiamo facendo?

1.1 Introduzione

Riguardo questo progetto possono essere poste moltissime domande (per essere gentili) riguardo la validità delle scelte modellistiche che sono state fatte. Per parafrasare le parole di Giorgio Parisi, dette durante l'intervista in occasione dell'incontro con gli studenti il giorno in cui gli è stato assegnato la laurea honoris causa in Fisica dei Sistemi Complessi, "esistono due tipi di scienziati che sono in grado di determinare un l'avanzamento di una certa disciplina, attraverso l'introduzione di nuovi punti di vista che si discostano dai modelli già noti, quelli che conoscono tutto della disciplina in questione e quindi si rendono perfettamente conto che è possibile adottare un nuovo punto di vista, e quelli che non conoscono praticamente nulla ma portano avanti lo stesso un nuovo punto di vista senza rendersi conto che è un nuovo punto di vista". Dove ci poniamo noi? Nella nosta posizione attuale possiamo solo sperre di trovarci nel seconodo caso.

1.2 Proviamo a rispondere ad alcune domande

Possiamo provare a considerare le seguenti domande e proviamo a darne una risposta.

- Perché il comportamento imitativo degli investitori dovrebbe essere descritto attraverso un modello di flocking?
- Quale meccanismo permette di collegare il comportamento collettivo degli agenti alle fluttuazioni del prezzo e alla volatilità di Bitcoin?
- Il nostro sistema è effettivamente un modello agent-based oppure una dinamica di particelle alla quale abbiamo attribuito un significato finanziario?

Risposta alla prima e alla seconda domanda Un possibile collegamento tra il mercato finanziario e il flocking è il comportamento imitativo degli investitori detto herding. Nel modello di Tamás Vicsek, particelle dotate di una direzione di moto tendono ad allinearsi con quelle vicine, pur essendo soggette a rumore. Un comportamento globalmente ordinato può emergere da interazioni locali, senza che esista un coordinatore centrale. In un mercato finanziario l'analogia può essere formulata nel seguente modo:
L'analogia non è puramente arbitraria. Già nel lavoro di Rama Cont e Jean-Philippe Bouchaud, Herd Behavior and Aggregate Fluctuations in Financial Markets (2000), il comportamento imitativo degli investitori viene collegato matematicamente alla comparsa di fluttuazioni aggregate con code pesanti. Anche Lux e Marchesi (1999) hanno mostrato che le interazioni tra investitori eterogenei possono generare dinamiche finanziarie complesse, comprese caratteristiche statistiche che ricordano quelle dei mercati reali.
Per le criptovalute esiste l'herding? Esistono evidenze empiriche, anche se il fenomeno non è uniforme né sempre attribuibile all'imitazione diretta. Uno studio di Gemayel e Preda (2024), Herding in the cryptocurrency market: A transaction-level analysis, analizza transazioni di operatori in mercati crypto e rileva comportamento gregario; una parte importante è però associata alla ripetizione delle proprie strategie passate, oltre che alle influenze dell'ambiente di mercato. Questo suggerisce una distinzione importante: non basta osservare che molti investitori agiscono nello stesso modo per concludere che si stiano imitando. Potrebbero essere tutti influenzati dalla stessa notizia, dalla stessa variazione di prezzo o dallo stesso indicatore tecnico. Perciò il nostro modello deve distinguere: Influenza sociale: un agente cambia comportamento perché osserva altri agenti e risposta comune, cioè più a genti cambiano comportamento perché ricevono lo stesso segnale esterno. Nel codice attuale il flocking rappresenta il primo meccanismo, mentre le correnti dipendenti dal rendimento e dalla volatilità rappresentano il secondo. Vediamo collegare matematicamente herding e volatilità. Consideriamo N agenti e definiamo una variabile decisionale:

$$s_i(t) \in \{-1, 0, +1\},$$

con il significato:

$$s_i(t) = \begin{cases} +1 & \text{intenzione di acquistare,} \\ 0 & \text{nessuna operazione,} \\ -1 & \text{intenzione di vendere.} \end{cases}$$

Per semplicità, supponiamo inizialmente che tutti gli agenti possano inviare ordini della stessa dimensione q. Definiamo la domanda netta intenzionale:

$$D(t) = q \sum_{i=1}^{N} s_i(t).$$

Questa grandezza non rappresenta il volume totale effettivamente eseguito: misura lo sbilanciamento tra gli ordini di acquisto e vendita che gli agenti vorrebbero effettuare. Consideriamo ora la sua varianza:

$$\mathrm{Var}[D(t)] = q^2 \,\mathrm{Var}\left[\sum_{i=1}^{N} s_i(t)\right].$$

Sviluppando:

$$\boxed{\mathrm{Var}[D(t)] = q^2 \left[\sum_{i=1}^{N} \mathrm{Var}[s_i(t)] + 2\sum_{i<j} \mathrm{Cov}[s_i(t), s_j(t)]\right].}$$

Questa equazione è fondamentale. Se gli agenti decidono indipendentemente, le covarianze tra le loro decisioni sono nulle. Per agenti identicamente distribuiti con varianza finita, otteniamo:

$$\mathrm{Var}[D(t)] \propto N.$$

Se invece gli agenti tendono a imitarsi, alcune covarianze diventano positive:

$$\mathrm{Cov}[s_i(t), s_j(t)] > 0.$$

La varianza della domanda netta aumenta. Nel limite ideale in cui tutti gli agenti adottano la stessa decisione aleatoria, essa può crescere come:

$$\mathrm{Var}[D(t)] \propto N^2.$$

upponiamo ora di introdurre un meccanismo semplificato di impatto sul prezzo:

$$r_t = \lambda D(t) + \varepsilon_t,$$

dove λ rappresenta la sensibilità del prezzo allo sbilanciamento degli ordini ed ε_t è una perturbazione indipendente da $D(t)$. Se λ è costante:

$$\boxed{\mathrm{Var}[r_t] = \lambda^2 \,\mathrm{Var}[D(t)] + \mathrm{Var}[\varepsilon_t].}$$

Da questa relazione segue che un aumento della variabilità della domanda netta può produrre un aumento della varianza dei rendimenti, quindi della volatilità. Abbiamo così ottenuto una catena causale all'interno del modello: Maggiore imitazione tra agenti → Maggiore correlazione tra decisioni → Maggiore variabilità degli sbilanciamenti degli ordini → Possibile aumento della volatilità dei rendimenti Questa derivazione dà una motivazione fisico-matematica concreta all'utilizzo del flocking Naturalmente, dipende dalle ipotesi adottate: il flocking non implica automaticamente un aumento della volatilità. Se tutti gli agenti comprassero sempre nella stessa misura, avremmo una forte pressione direzionale ma non necessariamente rendimenti molto variabili. Per generare fluttuazioni serve che lo sbilanciamento cambi, per esempio attraverso cambiamenti del coordinamento, rumore, limiti di portafoglio o transizioni tra comportamenti. Il passaggio dal flusso degli ordini alla variazione del prezzo trova anche sostegno empirico negli studi di microstruttura finanziaria: Cont, Kukanov e Stoikov hanno osservato una relazione tra variazioni di prezzo e sbilanciamento del flusso degli ordini, con un effetto dipendente dalla profondità del mercato. Il loro risultato riguarda titoli azionari, quindi non può essere trasferito quantitativamente a Bitcoin senza verifiche specifiche. Il collegamento appena ricavato riguarda la varianza dei rendimenti. Ma uno dei nostri obiettivi è riprodurre anche il volatility clustering, cioè la tendenza delle fasi turbolente a concentrarsi nel tempo. Per ottenere questa proprietà serve un ingrediente ulteriore: la persistenza temporale dello stato collettivo degli agenti. Immaginiamo che il mercato alterni periodi nei quali gli investitori agiscono indipendentemente a periodi nei quali si imitano fortemente. Se il grado di imitazione evolve lentamente, anche la variabilità degli sbilanciamenti degli ordini può mostrare una certa persistenza. Possiamo quindi ipotizzare:

$$\text{Herding persistente} \longrightarrow \text{Varianza persistente degli ordini} \longrightarrow \text{Volatilità persistente}.$$

È precisamente questo genere di meccanismo che rende interessanti gli ABM finanziari. Non è necessario imporre direttamente una volatilità elevata per un certo numero di giorni: possiamo tentare di farla emergere dall'organizzazione delle interazioni. Nel lavoro di Lux e Marchesi, per esempio, le proprietà statistiche delle fluttuazioni del mercato emergono dalle interazioni e dai cambiamenti nelle popolazioni di operatori. Per il nostro progetto la domanda diventa quindi: possiamo ottenere clustering della volatilità facendo evolvere soltanto le interazioni, il comportamento imitativo e le decisioni degli agenti? Questa sarebbe un'ipotesi scientifica verificabile, non una semplice analogia tra flocking e mercati finanziari.
Quanto di tutto questo è già presente nel nostro modello? Qui dobbiamo essere piuttosto critici.

Elemento attuale	**Criticità**	**Possibile miglioramento**
Flocking degli orientamenti (`heading`)	L'allineamento delle direzioni non coincide necessariamente con l'allineamento delle decisioni di trading	Collegare direttamente l'interazione sociale alle intenzioni di acquisto e vendita
Coordinata y	Determina buy/sell, ma è una rappresentazione astratta dell'opinione	Definirla esplicitamente come sentiment individuale
Coordinata x	La probabilità di trading cresce verso destra, ma non è chiaro perché debba seguire una dinamica spaziale	Interpretarla come propensione operativa e definire come evolve
Corrente legata ai rendimenti	Rappresenta una risposta comune al mercato, non necessariamente un fenomeno imitativo	Separare segnali pubblici e influenza sociale
Prezzo endogeno	Dipende dalla media delle coordinate y, non dagli ordini effettivamente presentati	Introdurre domanda netta e price impact
Volume del modello	Somma acquisti e vendite senza un meccanismo esplicito di esecuzione	Definire un mercato con matching oppure market maker

Tabella 1: Criticità del modello attuale e possibili miglioramenti.

Una criticità particolarmente importante: il parametro d'ordine Attualmente calcolate:

$$\Phi(t) = \frac{1}{N} \left| \sum_{i=1}^{N} \mathbf{u}_i(t) \right|,$$

dove $\mathbf{u}_i$ è il vettore unitario associato all'orientamento dell'agente. Questa grandezza misura quanto le direzioni degli agenti siano allineate, ma non misura necessariamente quanto siano concordi le loro decisioni finanziarie. Per esempio, due agenti possono avere la stessa direzione di moto e trovarsi uno nella regione buy e l'altro nella regione sell. Inoltre, un valore $\Phi \simeq 1$ indica forte allineamento, ma non dice se il mercato sia orientato all'acquisto oppure alla vendita. Per questo introdurrei due osservabili diverse:

$$\Phi(t) = \text{grado di allineamento geometrico,}$$

$$m(t) = \frac{1}{N} \sum_{i=1}^{N} s_i(t) = \text{sbilanciamento medio delle intenzioni.}$$

Il primo misura il flocking nel senso geometrico. Il secondo misura l'orientamento collettivo finanziario. Sarebbe interessante verificare se esista una relazione tra $\Phi(t)$ e $m(t)$, anziché assumere che le due grandezze siano equivalenti. Un problema tecnico da correggere in seguito Nel codice c'è anche un'incoerenza tra l'orientamento NetLogo e le componenti della velocità. In NetLogo, infatti:

$$dx = \sin(\texttt{heading}), \qquad dy = \cos(\texttt{heading}),$$

poiché la direzione 0° corrisponde al Nord, non all'asse x positivo come nella convenzione matematica usuale.

Risposta alla terza domanda ì, in senso metodologico lo è. Ma bisogna distinguere l'appartenenza alla famiglia degli ABM dall'adeguatezza del modello come descrizione economica. Un modello agent-based descrive un sistema attraverso entità individuali dotate di stati e regole di comportamento. Gli agenti possono essere eterogenei, interagire tra loro e con un ambiente comune e produrre dinamiche aggregate non specificate direttamente a livello globale. Questa impostazione è ampiamente utilizzata anche nei modelli finanziari. Nel nostro caso troviamo effettivamente tutti gli elementi fondamentali:
Quindi non c'è motivo di negare che sia un ABM. Tuttavia, nel modello attuale esistono anche componenti introdotte direttamente a livello macroscopico, come il fattore di memoria del prezzo applicato al volume. La presenza di componenti fenomenologiche macroscopiche non elimina il carattere agent-based, ma rende il modello ibrido tra regole microscopiche e chiusure fenomenologiche aggregate. Soprattutto, non possiamo ancora dire che prezzo e volatilità emergano da un meccanismo finanziario realistico. Che cosa manca per

Caratteristica ABM	Presenza nel modello
Agenti individuali	Le turtles rappresentano singoli operatori
Stato individuale	Posizione, velocità, Bitcoin detenuti e liquidità
Eterogeneità	Tre specie e portafogli iniziali differenti
Regole individuali	Flocking, spostamento, probabilità di trading
Interazioni	Reti di flockmates e repulsione tra specie
Stocasticità	Posizioni, direzioni e decisioni casuali
Grandezze aggregate	Prezzo, volume, parametro d'ordine

Tabella 2: Caratteristiche del modello ad agenti (ABM).

parlare di un mercato artificiale convincente?
La parte più debole è la compravendita. Nel codice, ogni agente modifica la propria liquidità e i Bitcoin detenuti quando decide di comprare o vendere. Non abbiamo però definito chi sia la sua controparte. Nel mondo reale, un acquisto eseguito deve corrispondere a una vendita eseguita. Inoltre, il prezzo può variare perché gli ordini aggrediscono livelli differenti di liquidità disponibile.

2 Elementi di teoria

2.1 Introduzione

Per la calibrazione dei nostro modello agent-based utilizzeremo il metodo noto come Method of Simulated Moments (MSM). Non chiediamo al modello di riprodurre una particolare traiettoria reale, ma di riprodurre le proprietà statistiche che caratterizzano il processo che l'ha generata. Come prima cosa si decide quali fenomeni il modello deve spiegare dopodichè si determina quali osservabili macroscopiche ha senso confrontare con i dati. Per essere più precisi, indichiamo con $\boldsymbol{\theta} = (\theta_1, \theta_2, \ldots, \theta_p)$ il vettore dei parametri controllabili dell'ABM. Nel nostro caso comprende, per esempio, temperature, hype-sensitivity, price-sensitivity, k, h, le dimensioni delle popolazioni e l'intensità delle interazioni. Indichiamo invece con $\mathbf{S} = (S_1, S_2, \ldots, S_q)$ il vettore delle statistiche macroscopiche che vogliamo riprodurre. Dai dati reali di Bitcoin ricaviamo un vettore di stime $\widehat{\mathbf{S}}_{\text{real}}$. Eseguendo molte simulazioni indipendenti, tutte con gli stessi parametri $\boldsymbol{\theta}$ ma con semi casuali diversi (condizioni iniziali), otteniamo: $\widehat{\mathbf{S}}^{(1)}(\boldsymbol{\theta}), \ldots, \widehat{\mathbf{S}}^{(M)}(\boldsymbol{\theta})$ Possiamo quindi stimare i valori medi prodotti dal modello:

$$\overline{\mathbf{S}}_{\text{ABM}}(\boldsymbol{\theta}) = \frac{1}{M} \sum_{j=1}^{M} \widehat{\mathbf{S}}^{(j)}(\boldsymbol{\theta}).$$

L'obiettivo è trovare parametri $\boldsymbol{\theta}^*$ che minimizzino la distanza statistica tra il sistema reale e quello simulato:

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} \left[\overline{\mathbf{S}}_{\text{ABM}}(\boldsymbol{\theta}) - \widehat{\mathbf{S}}_{\text{real}}\right]^T W \left[\overline{\mathbf{S}}_{\text{ABM}}(\boldsymbol{\theta}) - \widehat{\mathbf{S}}_{\text{real}}\right]$$

dove W è una matrice di pesi che permette di attribuire importanza diversa alle varie statistiche e tenere conto delle loro scale e, se stimabili, delle loro incertezze. Alla luce di questa spiegazione possiamo anche definire in modo rigoroso l'obiettivo scientifico del nostro modello, che possiamo formulare nel seguente modo: "Determinare se un sistema costituito da agenti eterogenei, governati da regole semplici di trading, flocking e interazione, possa generare spontaneamente serie temporali di prezzi e volumi con proprietà statistiche compatibili con quelle osservate nel mercato Bitcoin".

2.2 Come organizzare la simulazione

La procedura che possiamo seguire è la seguente:

1. Selezione dei dati reali. Scegliamo una serie storica di prezzo e volume di Bitcoin. Dobbiamo anche definire se il volume rappresenti un singolo exchange oppure un aggregato di mercato.

Approfondimento

Bitcoin non viene scambiato su un unico mercato centralizzato, ma su numerose piattaforme di compravendita, chiamate exchange, come Coinbase , Binance e Kraken. Ogni exchange registra autonomamente il prezzo delle transazioni e i volumi scambiati. Di conseguenza, quando parliamo di volume giornaliero di Bitcoin, dobbiamo specificare esattamente a quali transazioni ci riferiamo. Se utilizziamo i dati di un singolo exchange, possiamo interpretare il nostro ABM come una rappresentazione semplificata degli operatori che scambiano su quella piattaforma. Se invece utilizziamo dati aggregati, il modello rappresenterebbe un mercato più ampio, composto da operatori distribuiti tra diverse piattaforme.Questa distinzione influenza soprattutto la scala dei volumi. Inoltre, il prezzo non è necessariamente identico su tutti gli exchange: piccole differenze possono derivare dalla liquidità, dalla struttura degli ordini e dalle condizioni operative dei singoli mercati.Inoltre, il prezzo non è necessariamente identico su tutti gli exchange: piccole differenze possono derivare dalla liquidità, dalla struttura degli ordini e dalle condizioni operative dei singoli mercati.

2. Stima delle statistiche empiriche. Calcoliamo le statistiche selezionate e la loro incertezza. Poiché i dati sono temporalmente correlati, possiamo utilizzare tecniche come il block bootstrap (vedremo dopo) per ottenere intervalli di confidenza.

3. Simulazioni Monte Carlo. Fissiamo $\boldsymbol{\theta}$, eseguiamo inizialmente, per esempio, 100–200 simulazioni indipendenti e stimiamo media e dispersione delle statistiche simulate.

4. Calibrazione. Modifichiamo i parametri fenomenologici per minimizzare la funzione obiettivo. Possiamo iniziare con una ricerca su griglia o casuale e passare successivamente a metodi più efficienti.

Approfondimento

Una volta definita la funzione obiettivo della calibrazione, dobbiamo scegliere un algoritmo che individui i valori dei parametri fenomenologici dell'ABM capaci di riprodurre meglio le statistiche macroscopiche del mercato reale. Questo è un problema di ottimizzazione numerica, con una difficoltà aggiuntiva: il nostro modello è stocastico, cioè un certo insieme di parametri potrebbe sembrare migliore di un altro soltanto per fluttuazioni statistiche. Esistono alcuni algoritmi i più semplici sono grid search dove per er ciascun parametro definiamo un insieme discreto di valori e proviamo tutte le combinazioni possibili, che ha chiaramente uno svantaggio dal punto di vista computazionale, e random search, dove estraiamo casualmente combinazioni di parametri all'interno degli intervalli consentiti. Per citare un metodo più sofisticato, possiamo considerare l'algoritmo di ottimizzazione bayesiana, che potrebbe essere utile quando il costo computazionale di una singola simulazione è elevato.

5. Validazione. Una volta scelti i parametri, verifichiamo che il modello riproduca le statistiche anche su dati non utilizzati per la calibrazione. Qui non dobbiamo modificare nuovamente i parametri per inseguire i risultati.

6. Studio dei meccanismi. Variamo singolarmente o congiuntamente i parametri, disattiviamo, hype o interazioni tra specie e studiamo come cambiano le osservabili macroscopiche.

Nella prima parte dei dati scegliamo i parametri. Nella seconda controlliamo se le scelte generalizzano e selezioniamo eventuali modifiche strutturali. Nella terza, mai utilizzata durante lo sviluppo, misuriamo le prestazioni finali. Per una serie finanziaria non basta necessariamente una sola divisione temporale. Bitcoin attraversa regimi differenti e le sue proprietà statistiche possono cambiare nel tempo. Per questo sarà utile ripetere l'analisi su più periodi e confrontare separatamente fasi calme, rialziste e turbolente, evitando di classificare i regimi sulla base dei risultati del modello stesso. Un risultato interessante sarebbe verificare che la medesima parametrizzazione riesca a riprodurre diverse proprietà statistiche in periodi differenti.

2.3 Statistiche macroscopiche

Il nostro modello parte dal presupposto che la definizione di mercato reale sia quella di un sistema finanziario caratterizzato da dal prezzo e dai volumi scambiati in un certo intervallo temporale. In particolare abbiamo considerato una serie $T+1$ osservazioni giornaliere, con:

- P_t prezzo di Bitcoin in USD alla fine del giorno t;
- V_t: volume effettivamente scambiato durante il giorno t, espresso in USD.

Perciò le variabili su cui dovremo concentrare la nostra analisi saranno delle grandezze statistiche legate a P_t e V_t. In particolare, abbiamo che spesso, per quanto riguarda i prezzi, si preferisce lavorare l log-rendimento:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \qquad t = 1, \dots, T.$$

mentre per il volume introduciamo una trasformazione logaritmica:

$$v_t = \ln\left(1 + \frac{V_t}{V_*}\right),$$

dove $V_* > 0$ è una scala di riferimento fissata usando esclusivamente il campione di calibrazione, e mantenuta identica per dati reali e simulati. Questa trasformazione riduce l'influenza degli enormi picchi di volume, preservando comunque l'informazione sulla loro intensità. Il sistema reale viene quindi rappresentato attraverso un processo stocastico bivariato $\mathbf{X}_t = (r_t, v_t)$. Il compito dell'ABM sarà generare un processo $\mathbf{X}_t^{\text{ABM}}$ statisticamente compatibile con quello empirico. Per ora, per introduciamo un numero limitato di statistiche, questo perchè più statistiche introduciamo, più difficile diventa comprendere quali meccanismi siano effettivamente responsabili dell'accordo con i dati. Consideriamo otto statistiche che dividiamo in 3 gruppi (la definizione rigorosa è subito dopo le tabelle):

1. Statistiche dei rendimenti

Statistica	**Simbolo**	**Proprietà fisico-finanziaria**
Deviazione standard dei log-rendimenti	$S_1 = \sigma_r$	Scala delle fluttuazioni del prezzo
Quantile al 99% di $\lvert r_t \rvert$	$S_2 = Q_{0.99}(\lvert r \rvert)$	Intensità degli eventi estremi
Autocorrelazione di $\lvert r_t \rvert$, ritardo 1	$S_3 = \rho_{\lvert r \rvert}(1)$	Persistenza della volatilità a breve termine
Autocorrelazione di $\lvert r_t \rvert$, ritardo 7	$S_4 = \rho_{\lvert r \rvert}(7)$	Persistenza della volatilità a una settimana

Tabella 3: Statistiche utilizzate per caratterizzare i rendimenti.

2. Statistiche dei volumi

Statistica	**Simbolo**	**Proprietà**
Mediana dei log-volumi	$S_5 = \text{Med}(v)$	Livello tipico dell'attività di mercato
Deviazione standard dei log-volumi	$S_6 = \sigma_v$	Variabilità dell'attività di trading
Autocorrelazione dei log-volumi, ritardo 1	$S_7 = \rho_v(1)$	Persistenza temporale dell'attività di trading

Tabella 4: Statistiche utilizzate per caratterizzare i log-volumi.

3. Statistica congiunta prezzo-volume: una proprietà particolarmente importante per il nostro progetto è la relazione tra attività di trading e intensità delle variazioni del prezzo $S_8 = \text{Corr}(v_t, \lvert r_t \rvert)$.Questa correlazione misura se i periodi caratterizzati da fluttuazioni intense sono associati a una maggiore attività di mercato. Un ABM potrebbe riprodurre correttamente la distribuzione dei rendimenti e quella dei volumi separatamente, ma non la loro relazione reciproca. In quel caso mancherebbe un elemento fondamentale della dinamica finanziaria.

quindi complessivamente il vettore delle statistiche è:

$$\mathbf{S} = \begin{pmatrix} \sigma_r \\ Q_{0.99}(\lvert r \rvert) \\ \rho_{\lvert r \rvert}(1) \\ \rho_{\lvert r \rvert}(7) \\ \text{Med}(v) \\ \sigma_v \\ \rho_v(1) \\ \text{Corr}(v, \lvert r \rvert) \end{pmatrix}.$$

2.3.1 Definizione matematica degli stimatori

Media e deviazione standard
Per una serie $x_1, \ldots, x_T$, definiamo:

$$\widehat{\mu}_x = \frac{1}{T}\sum_{t=1}^{T} x_t$$

e

$$\widehat{\sigma}_x = \sqrt{\frac{1}{T-1}\sum_{t=1}^{T}(x_t - \widehat{\mu}_x)^2}.$$

Applicando questo stimatore ai rendimenti otteniamo $\widehat{S}_1$; applicandolo ai log-volumi otteniamo $\widehat{S}_6$.

Quantile degli eventi estremi

Lo stimatore $\widehat{S}_2$ è il quantile empirico al livello 0.99 della serie:

$$|r_1|, |r_2|, \ldots, |r_T|.$$

Utilizzeremo la stessa convenzione di interpolazione dei quantili in tutte le elaborazioni. Il quantile è una misura diretta dell'ampiezza dei movimenti estremi. Come controllo secondario potremo considerare anche la curtosi in eccesso, che però può essere particolarmente instabile in presenza di osservazioni estreme.

Autocorrelazione

Per una serie x_t, lo stimatore dell'autocorrelazione al ritardo ℓ è:

$$\widehat{\rho}_x(\ell) = \frac{\displaystyle\sum_{t=\ell+1}^{T}(x_t - \widehat{\mu}_x)(x_{t-\ell} - \widehat{\mu}_x)}{\displaystyle\sum_{t=1}^{T}(x_t - \widehat{\mu}_x)^2}.$$

Da questa espressione ricaviamo:

$$\widehat{S}_3 = \widehat{\rho}_{|r|}(1), \qquad \widehat{S}_4 = \widehat{\rho}_{|r|}(7), \qquad \widehat{S}_7 = \widehat{\rho}_v(1).$$

Correlazione prezzo-volume

La correlazione congiunta viene stimata mediante:

$$\widehat{S}_8 = \frac{\sum_t (v_t - \bar{v})(|r_t| - \overline{|r|})}{\sqrt{\sum_t (v_t - \bar{v})^2}\sqrt{\sum_t (|r_t| - \overline{|r|})^2}}.$$

Il risultato appartiene all'intervallo $[-1, 1]$. Se una delle serie è costante, la correlazione è matematicamente non definita: in fase di validazione non la considereremo equivalente a zero, ma registreremo il caso come una degenerazione del modello. Per la mediana dei log-volumi, $\widehat{S}_5$, utilizzeremo la mediana campionaria ordinaria. Queste definizioni costituiscono il nostro protocollo di misurazione. Non dovranno cambiare durante la calibrazione.

2.4 Stima dell'incertezza delle statistiche empiriche

Le statistiche macroscopiche introdotte precedentemente non sono quantità note esattamente, ma vengono stimate a partire da un numero finito di osservazioni del mercato reale. Di conseguenza, ogni statistica empirica è soggetta a una certa incertezza.

Indicando con S_i una generica proprietà statistica del processo reale, la sua stima campionaria sarà

$$\widehat{S}_i^{\text{real}}.$$

L'obiettivo è associare a ciascuna stima una misura della sua incertezza, generalmente rappresentata dall'errore standard:

$$\text{SE}\left(\widehat{S}_i^{\text{real}}\right).$$

L'errore standard quantifica la variabilità che lo stimatore presenterebbe se fosse possibile ripetere il campionamento dal medesimo processo stocastico. Non deve essere confuso con la deviazione standard delle osservazioni: quest'ultima descrive la variabilità dei dati, mentre l'errore standard descrive l'incertezza della statistica stimata.

2.4.1 Dipendenza temporale e volatility clustering

Una delle principali difficoltà nell'analisi delle serie finanziarie consiste nel fatto che le osservazioni successive non sono necessariamente indipendenti.
Nei mercati finanziari si osserva frequentemente un fenomeno noto come *volatility clustering*, o raggruppamento temporale della volatilità.
Questo fenomeno consiste nella tendenza delle variazioni di prezzo di grande ampiezza a concentrarsi temporalmente: periodi caratterizzati da forti oscillazioni sono spesso seguiti da altri periodi di elevata volatilità, mentre periodi relativamente tranquilli tendono a essere seguiti da ulteriori periodi di bassa volatilità.
Per comprendere matematicamente questo comportamento, consideriamo i log-rendimenti:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right).$$

In numerose serie finanziarie, l'autocorrelazione dei rendimenti è relativamente debole:

$$\mathrm{Corr}(r_t, r_{t+\tau}) \approx 0,$$

mentre quella dei rendimenti assoluti, oppure dei rendimenti quadratici, può risultare positiva e persistente:

$$\mathrm{Corr}(|r_t|, |r_{t+\tau}|) > 0,$$

$$\mathrm{Corr}(r_t^2, r_{t+\tau}^2) > 0.$$

I rendimenti assoluti e quadratici vengono quindi frequentemente utilizzati come indicatori dell'intensità delle fluttuazioni, pur non coincidendo necessariamente con la volatilità condizionale del processo.
Questo significa che la direzione delle variazioni future del prezzo può essere difficilmente prevedibile, mentre la loro intensità può presentare una significativa dipendenza temporale.
Il volatility clustering costituisce quindi una proprietà statistica che desideriamo verificare e, se presente nei dati reali, riprodurre attraverso il modello agent-based.
La presenza di dipendenze temporali deve essere considerata anche durante la stima dell'incertezza statistica. In particolare, non possiamo trattare automaticamente tutte le osservazioni come realizzazioni indipendenti della medesima distribuzione.

2.4.2 Il metodo bootstrap

Il *bootstrap* è una tecnica statistica di ricampionamento che permette di stimare l'incertezza di una statistica utilizzando direttamente i dati osservati.
Supponiamo di disporre di un campione

$$X = (x_1, x_2, \ldots, x_T)$$

e di voler stimare una certa statistica S, ad esempio la media, la varianza, un quantile oppure una correlazione.
Calcoliamo inizialmente lo stimatore sul campione originale:

$$\widehat{S} = S(X).$$

L'idea del bootstrap consiste nel costruire artificialmente molti nuovi campioni, detti *campioni bootstrap*, estraendo osservazioni dal campione originale con reinserimento.
L'estrazione con reinserimento significa che una stessa osservazione può essere selezionata più volte, mentre altre osservazioni possono non comparire nel nuovo campione.
Ogni campione bootstrap ha normalmente la stessa numerosità T del campione originale:

$$X^{*(b)} = (x_1^{*(b)}, x_2^{*(b)}, \ldots, x_T^{*(b)}),$$

dove $b = 1, \ldots, B$ identifica la replica bootstrap.
Per ciascuna replica si calcola nuovamente la statistica:

$$\widehat{S}^{*(b)} = S(X^{*(b)}).$$

Ripetendo la procedura B volte, si ottiene una distribuzione empirica dello stimatore:

$$\left\{\widehat{S}^{*(1)}, \widehat{S}^{*(2)}, \ldots, \widehat{S}^{*(B)}\right\}.$$

Questa distribuzione permette di approssimare la variabilità campionaria dello stimatore originale.
In particolare, l'errore standard bootstrap viene stimato come

$$\widehat{\mathrm{SE}}_{\mathrm{boot}}(\widehat{S}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\widehat{S}^{*(b)} - \overline{S}^{*}\right)^2},$$

dove

$$\overline{S}^{*} = \frac{1}{B}\sum_{b=1}^{B}\widehat{S}^{*(b)}.$$

Inoltre, utilizzando i quantili della distribuzione bootstrap, è possibile costruire un intervallo di confidenza approssimato.

Quantili, percentili e intervalli di confidenza Una volta costruiti numerosi campioni bootstrap, possiamo utilizzare le statistiche calcolate su tali campioni per stimare l'incertezza associata alla statistica ottenuta dai dati reali.
Prima di descrivere questa procedura, è necessario distinguere alcuni concetti fondamentali della statistica inferenziale.

Definizione di quantile e percentile.
Consideriamo una variabile aleatoria reale Y, caratterizzata dalla funzione di distribuzione cumulativa

$$F_Y(y) = \Pr(Y \le y).$$

Il *quantile di ordine* p, con $0 < p < 1$, è definito come

$$\boxed{Q_p(Y) = \inf\{y \in \mathbb{R} : F_Y(y) \ge p\}.}$$

In termini intuitivi, il quantile Q_p rappresenta una soglia al di sotto della quale si trova una frazione almeno pari a p della distribuzione.
Ad esempio:

- $Q_{0.50}$ è il quantile di ordine 0.50, comunemente chiamato *mediana*;
- $Q_{0.025}$ è il quantile di ordine 0.025, corrispondente al percentile 2.5%;
- $Q_{0.975}$ è il quantile di ordine 0.975, corrispondente al percentile 97.5%.

Il termine *percentile* esprime quindi lo stesso concetto utilizzando una scala percentuale anziché un numero compreso tra zero e uno.
Per esempio, il percentile 97.5% indica una soglia al di sotto della quale si trova approssimativamente il 97.5% delle osservazioni.

Costruzione dei quantili bootstrap.
Supponiamo di avere generato B campioni bootstrap e di avere calcolato su ciascuno di essi la statistica di interesse:

$$\widehat{S}^{*(1)}, \widehat{S}^{*(2)}, \ldots, \widehat{S}^{*(B)}.$$

Il simbolo $*$ indica che la statistica è stata ottenuta da un campione bootstrap, anziché direttamente dal campione originale.
Possiamo ordinare i valori ottenuti in ordine crescente:

$$\widehat{S}^{*}_{(1)} \le \widehat{S}^{*}_{(2)} \le \cdots \le \widehat{S}^{*}_{(B)}.$$

I quantili empirici vengono ricavati dalla posizione occupata dai valori nella sequenza ordinata.
Per esempio, se consideriamo

$$B = 1000,$$

il percentile 2.5% si trova approssimativamente in corrispondenza della venticinquesima osservazione ordinata, mentre il percentile 97.5% si trova approssimativamente in corrispondenza della novecentosettantacinquesima.

La posizione esatta può dipendere dalla convenzione di interpolazione utilizzata per calcolare i quantili empirici.
In questo modo otteniamo due valori:

$$Q_{0.025}(\widehat{S}^*), \qquad Q_{0.975}(\widehat{S}^*).$$

Tra questi due estremi si trova approssimativamente il 95% centrale della distribuzione bootstrap, poiché vengono esclusi il 2.5% inferiore e il 2.5% superiore dei valori.

Costruzione dell'intervallo di confidenza percentile.
Un *intervallo di confidenza* è un intervallo calcolato a partire dai dati osservati, mediante una procedura statistica progettata per contenere il parametro teorico sconosciuto con una determinata frequenza di copertura. Nel metodo bootstrap percentile, un intervallo di confidenza bilaterale con livello nominale $1-\alpha$ viene costruito come

$$IC_{1-\alpha}(\widehat{S}) = \left[Q_{\alpha/2}(\widehat{S}^*), Q_{1-\alpha/2}(\widehat{S}^*)\right].$$

Il parametro α rappresenta la probabilità nominale complessiva lasciata nelle due code della distribuzione. Per un intervallo al 95% scegliamo

$$1 - \alpha = 0.95,$$

da cui

$$\alpha = 0.05.$$

Poiché consideriamo un intervallo bilaterale, suddividiamo questa probabilità equamente tra le due code:

$$\frac{\alpha}{2} = 0.025.$$

Otteniamo quindi

$$\boxed{IC_{95\%}(\widehat{S}) = \left[Q_{0.025}(\widehat{S}^*), Q_{0.975}(\widehat{S}^*)\right].}$$

Questa procedura prende il nome di *metodo percentile* perché utilizza direttamente i percentili della distribuzione delle stime bootstrap per determinare gli estremi dell'intervallo.

Esempio numerico.
Supponiamo di voler stimare la correlazione tra i log-volumi e i rendimenti assoluti:

$$S = \mathrm{Corr}(v_t, |r_t|).$$

Dai dati reali otteniamo una stima campionaria

$$\widehat{S} = 0.40.$$

Generiamo successivamente 1000 campioni bootstrap e calcoliamo la stessa correlazione su ciascuno di essi. Supponiamo che i quantili della distribuzione bootstrap risultino

$$Q_{0.025}(\widehat{S}^*) = 0.28,$$

$$Q_{0.975}(\widehat{S}^*) = 0.52.$$

L'intervallo percentile al 95% sarà

$$\boxed{IC_{95\%} = [0.28, 0.52].}$$

Il valore 0.40 costituisce la stima puntuale del parametro, mentre l'intervallo $[0.28, 0.52]$ fornisce una rappresentazione dell'incertezza campionaria associata a tale stima.
Un intervallo relativamente stretto indica una maggiore precisione della stima, mentre un intervallo ampio segnala una maggiore incertezza.
Questa interpretazione presuppone tuttavia che la procedura bootstrap sia appropriata per la struttura statistica dei dati analizzati.

Interpretazione frequentista dell'intervallo di confidenza.

È importante chiarire il significato dell'espressione "intervallo di confidenza al 95%".
Nell'impostazione frequentista, il parametro teorico S viene considerato una quantità fissa, sebbene sconosciuta. L'intervallo di confidenza, invece, è casuale prima di osservare il campione, perché i suoi estremi dipendono dai dati utilizzati per costruirlo.
Supponiamo idealmente di poter ripetere il seguente esperimento molte volte:

1. estraiamo un nuovo campione di dati dal medesimo processo stocastico;
2. calcoliamo la statistica campionaria $\widehat{S}$;
3. applichiamo la procedura bootstrap;
4. costruiamo un intervallo di confidenza al 95%.

Ogni ripetizione produrrà generalmente un intervallo diverso, poiché cambieranno i dati osservati.
Indichiamo con

$$L(X), \qquad U(X)$$

gli estremi inferiore e superiore dell'intervallo costruito a partire dal campione casuale X.
Una procedura con copertura effettiva pari al 95% soddisfa

$$\boxed{\Pr\left(L(X) \leq S \leq U(X)\right) = 0.95.}$$

La probabilità è riferita alla ripetizione del campionamento e alla conseguente variabilità degli intervalli costruiti. In altre parole, se ripetessimo idealmente l'intera procedura un numero molto elevato di volte, circa il 95% degli intervalli ottenuti conterrebbe il vero parametro S. Non significa invece che, dopo avere osservato i dati e costruito uno specifico intervallo, il parametro fisso abbia una probabilità del 95% di trovarsi al suo interno. Una volta osservato il campione, l'intervallo è determinato e il parametro teorico o appartiene all'intervallo oppure non vi appartiene. La probabilità del 95% caratterizza quindi la procedura inferenziale, non il parametro sconosciuto.

Limiti e validità dell'intervallo bootstrap. Occorre infine precisare che il livello di confidenza nominale non coincide necessariamente con la copertura effettiva. Il metodo percentile fornisce un intervallo approssimato, la cui accuratezza dipende da diversi fattori, tra cui:

- il numero di osservazioni disponibili;
- la regolarità della distribuzione campionaria dello stimatore;
- l'eventuale presenza di distorsione sistematica dello stimatore;
- la dipendenza temporale tra le osservazioni;
- l'adeguatezza del metodo di ricampionamento utilizzato.

Per le serie finanziarie, nelle quali possono essere presenti autocorrelazioni e volatility clustering, utilizzeremo un metodo di ricampionamento a blocchi, come il moving block bootstrap, anziché il bootstrap ordinario. Inoltre, se lo stimatore presenta una distribuzione particolarmente asimmetrica o una distorsione significativa, il metodo percentile potrebbe non fornire la copertura desiderata. In tali situazioni possono essere necessarie procedure di costruzione degli intervalli più accurate. Nel nostro progetto, gli intervalli bootstrap saranno quindi utilizzati come stime dell'incertezza delle statistiche macroscopiche osservate nel mercato reale, verificandone la stabilità rispetto alle scelte di ricampionamento.

2.4.3 Moving block bootstrap

Il bootstrap ordinario, descritto precedentemente, è generalmente appropriato quando le osservazioni possono essere considerate indipendenti e identicamente distribuite. Nel nostro caso, tuttavia, stiamo analizzando una serie temporale finanziaria che può presentare dipendenze tra osservazioni successive, come quelle dovute al volatility clustering. Ricampionare singolarmente i rendimenti distruggerebbe la loro organizzazione temporale e, di conseguenza, parte dell'informazione sulla persistenza delle fluttuazioni. Per affrontare questo problema possiamo utilizzare il *moving block bootstrap*. La differenza fondamentale rispetto al bootstrap ordinario è che, invece di estrarre singole osservazioni, vengono estratti blocchi consecutivi di dati.
Consideriamo la serie temporale

$$X = (x_1, x_2, \ldots, x_T)$$

e fissiamo una lunghezza di blocco ℓ. Costruiamo tutti i possibili blocchi consecutivi sovrapposti di lunghezza ℓ:

$$B_1 = (x_1, \ldots, x_\ell),$$

$$B_2 = (x_2, \ldots, x_{\ell+1}),$$

$$\vdots$$

$$B_{T-\ell+1} = (x_{T-\ell+1}, \ldots, x_T).$$

Il termine *moving* si riferisce proprio al fatto che la finestra utilizzata per costruire i blocchi viene spostata progressivamente lungo la serie temporale. Successivamente, alcuni di questi blocchi vengono estratti casualmente con reinserimento e concatenati fino a ottenere una nuova serie di lunghezza almeno pari a T. Gli eventuali elementi eccedenti vengono eliminati. In questo modo si costruisce un nuovo campione bootstrap:

$$X^{*(b)} = B_{j_1} \| B_{j_2} \| \cdots \| B_{j_m},$$

opportunamente troncato alla lunghezza T, dove il simbolo $\|$ indica la concatenazione dei blocchi. Il vantaggio è che l'ordine delle osservazioni all'interno di ciascun blocco viene conservato. Pertanto, una parte della struttura di correlazione temporale presente nei dati originali viene mantenuta. Ad esempio, se un blocco contiene diversi giorni consecutivi di forte volatilità, questi giorni rimangono consecutivi anche nella replica bootstrap. È importante sottolineare che le correlazioni tra blocchi differenti non vengono necessariamente preservate. La qualità dell'approssimazione dipende quindi anche dalla scelta della lunghezza ℓ. Blocchi troppo corti rischiano di distruggere le dipendenze temporali rilevanti, mentre blocchi troppo lunghi riducono il numero di configurazioni distinte che è possibile ottenere dal campione originale. La scelta di ℓ rappresenta quindi un ulteriore problema statistico, da affrontare mediante criteri appropriati e analisi di sensibilità.

2.4.4 Applicazione alle statistiche del mercato Bitcoin

Nel nostro caso disponiamo di due serie temporali osservate:

$$r_t = \text{log-rendimento del prezzo},$$

$$v_t = \text{log-volume degli scambi}.$$

Poiché desideriamo stimare anche statistiche che coinvolgono simultaneamente prezzo e volume, come

$$\mathrm{Corr}(v_t, |r_t|),$$

è importante preservare la corrispondenza temporale tra le due grandezze. Per questo motivo, il ricampionamento non viene effettuato separatamente sulle due serie, ma sulla serie vettoriale:

$$\mathbf{X}_t = \begin{pmatrix} r_t \\ v_t \end{pmatrix}.$$

Ogni blocco bootstrap contiene quindi coppie consecutive di rendimento e volume. Questo permette di conservare, almeno all'interno dei blocchi, sia le dipendenze temporali sia le relazioni contemporanee tra le due variabili.
Per ogni replica bootstrap calcoliamo nuovamente l'intero vettore delle statistiche macroscopiche:

$$\widehat{\mathbf{S}}^{*(b)} = \begin{pmatrix} \widehat{S}_1^{*(b)} \\ \widehat{S}_2^{*(b)} \\ \vdots \\ \widehat{S}_8^{*(b)} \end{pmatrix}.$$

L'insieme delle repliche permette di stimare gli errori standard delle singole statistiche e la loro matrice di covarianza:

$$\widehat{\Sigma}_{\text{real}} = \frac{1}{B-1} \sum_{b=1}^{B} \left(\widehat{\mathbf{S}}^{*(b)} - \overline{\mathbf{S}}^{*} \right) \left(\widehat{\mathbf{S}}^{*(b)} - \overline{\mathbf{S}}^{*} \right)^{T},$$

dove

$$\overline{\mathbf{S}}^{*} = \frac{1}{B} \sum_{b=1}^{B} \widehat{\mathbf{S}}^{*(b)}.$$

Questa matrice contiene sia le incertezze associate alle singole statistiche sia le correlazioni tra i rispettivi errori di stima.
Tali informazioni saranno utili durante la calibrazione del modello, perché permetteranno di attribuire un peso differente agli scostamenti tra statistiche reali e simulate. In una prima implementazione possiamo utilizzare $B = 1000$ repliche bootstrap, verificando successivamente la stabilità dei risultati rispetto al numero di repliche e alla lunghezza dei blocchi.
L'applicabilità del moving block bootstrap richiede comunque ipotesi sulla struttura di dipendenza e sulla regolarità del processo, tipicamente una forma di stazionarietà debole con dipendenze sufficientemente decrescenti. In presenza di cambiamenti strutturali o regimi di mercatomolto differenti, sarà necessario valutare se analizzare separatamente i diversi intervalli temporali.
Al termine di questa procedura, per ciascuna statistica macroscopica disporremo quindi di una stima empirica, di un errore standard e di un intervallo di confidenza, che costituiranno il riferimento quantitativo per la successiva calibrazione del modello agent-based.

2.4.5 Stima delle statistiche del modello tramite Monte Carlo

Per ogni scelta di $\boldsymbol{\theta}$, eseguiamo M simulazioni indipendenti:

$$\mathbf{S}^{(1)}(\boldsymbol{\theta}), \ldots, \mathbf{S}^{(M)}(\boldsymbol{\theta}).$$

Ogni simulazione produce una serie di prezzi e volumi, dalla quale calcoliamo le medesime otto statistiche empiriche. Stimiamo il vettore medio:

$$\overline{\mathbf{S}}(\boldsymbol{\theta}) = \frac{1}{M} \sum_{j=1}^{M} \mathbf{S}^{(j)}(\boldsymbol{\theta})$$

e la matrice di covarianza delle statistiche simulate:

$$\widehat{\Sigma}_{\text{sim}}(\boldsymbol{\theta}) = \frac{1}{M-1} \sum_{j=1}^{M} \left(\mathbf{S}^{(j)} - \overline{\mathbf{S}} \right) \left(\mathbf{S}^{(j)} - \overline{\mathbf{S}} \right)^{T}.$$

Questa seconda grandezza è essenziale perchè non vogliamo soltanto un modello che produca statistiche corrette in media: vogliamo anche capire quanto i risultati varino tra una simulazione e l'altra. È utile distinguere tra la dispersione delle statistiche delle singole simulazioni, descritta da $\widehat{\Sigma}_{\text{sim}}$, e l'incertezza Monte Carlo sulla loro media, che è invece proporzionale a $\widehat{\Sigma}_{\text{sim}}/M$. Possiamo ora definire una funzione obiettivo:

$$\mathcal{L}(\boldsymbol{\theta}) = \left(\overline{\mathbf{S}}(\boldsymbol{\theta}) - \widehat{\mathbf{S}}_{\text{real}} \right)^{T} W \left(\overline{\mathbf{S}}(\boldsymbol{\theta}) - \widehat{\mathbf{S}}_{\text{real}} \right).$$

La scelta dei pesi W è importante perché le diverse statistiche hanno scale e precisioni diverse. Per una prima implementazione possiamo utilizzare una matrice diagonale:

$$W_{ii} = \frac{1}{\text{SE}(\widehat{S}_i^{\text{real}})^2 + \epsilon_i},$$

con regolarizzatori $\epsilon_i > 0$ scelti per evitare pesi eccessivi o numericamente instabili. L'obiettivo diventa:

$$\boxed{\boldsymbol{\theta}^{*} = \arg\min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta})}$$

Il modello è calibrato quando troviamo parametri che rendono sufficientemente vicine le statistiche simulate e quelle empiriche. Attenzione però non significa ancora che il modello sia validato. Abbiamo soltanto trovato una configurazione che riproduce bene il campione utilizzato durante la calibrazione.

2.5 Test statistici

- **Test diagnostici sulle serie**

  Per verificare se le serie temporali generate dal modello agent-based riproducono alcune delle proprietà statistiche osservate nel mercato reale, possiamo utilizzare diversi test di ipotesi. Un test statistico è una procedura che permette di valutare la compatibilità dei dati osservati con una determinata ipotesi, detta *ipotesi nulla* (H_0), confrontandola con un'ipotesi alternativa (H_1). Il risultato del test viene generalmente espresso attraverso un *p-value*, che rappresenta, assumendo vera l'ipotesi nulla, la probabilità di ottenere una statistica test almeno altrettanto estrema di quella osservata, nella direzione specificata dal test.

  Fissato un livello di significatività α, comunemente pari a 0.05, si rifiuta H_0 quando

  $$p\text{-value} < \alpha.$$

  Se invece il p-value è maggiore o uguale ad α, non si dispone di evidenza statistica sufficiente per rifiutare H_0. Questo non equivale a dimostrare che l'ipotesi nulla sia vera. Nel nostro caso utilizzeremo principalmente i seguenti test:

Test	**Ipotesi nulla**	**Utilità**
Ljung–Box sui rendimenti	Assenza di autocorrelazione lineare fino a un ritardo prefissato	Verificare la dipendenza temporale lineare dei rendimenti
Ljung–Box sui rendimenti assoluti	Assenza di autocorrelazione nei rendimenti assoluti fino a un ritardo prefissato	Individuare la persistenza temporale dell'ampiezza delle fluttuazioni
ARCH–LM	Assenza di effetti ARCH fino all'ordine considerato	Individuare una dipendenza della varianza condizionale dai rendimenti quadratici passati

Tabella 5: Test statistici utilizzati per l'analisi delle serie dei rendimenti.

- Test di compatibilità sulle singole statistiche
  Una volta calibrato il modello, generiamo un nuovo insieme indipendente di simulazioni. Per ogni statistica S_i, costruiamo l'intervallo predittivo Monte Carlo:

  $$I_i^{95\%}(\boldsymbol{\theta}^*) = \left[Q_{0.025}(S_i^{\text{sim}}), Q_{0.975}(S_i^{\text{sim}})\right].$$

  Se la statistica reale cade all'interno di questo intervallo, il risultato è compatibile con la variabilità prevista dal modello per quella statistica, al livello considerato. Per esempio, se la correlazione volume-volatilità osservata fosse 0.42, mentre il modello producesse nelle varie simulazioni valori compresi prevalentemente tra 0.10 e 0.25, avremmo un'evidenza di disaccordo, anche se altre statistiche fossero riprodotte correttamente. Bisogna però considerare che effettuando otto confronti separati aumenta la probabilità di osservare almeno un risultato estremo per puro caso. Gli intervalli individuali non sostituiscono quindi una verifica congiunta.

- Test globale di compatibilità
  Sia $\widehat{\mathbf{S}}_{\text{test}}$ il vettore delle statistiche ottenuto da dati reali non utilizzati durante la calibrazione. Costruiamo una distanza:

  $$D_{\text{obs}} = \left(\widehat{\mathbf{S}}_{\text{test}} - \overline{\mathbf{S}}_{\text{sim}}\right)^T W_{\text{test}} \left(\widehat{\mathbf{S}}_{\text{test}} - \overline{\mathbf{S}}_{\text{sim}}\right),$$

  dove W_{test} è fissata prima di osservare i risultati del test, per esempio utilizzando una matrice di covarianza regolarizzata delle statistiche simulate. Calcoliamo poi una distanza analoga per ciascuna simulazione indipendente, rispetto a un riferimento simulato stimato separatamente:

  $$D_j = \left(\mathbf{S}_{\text{sim}}^{(j)} - \overline{\mathbf{S}}_{\text{ref}}\right)^T W_{\text{test}} \left(\mathbf{S}_{\text{sim}}^{(j)} - \overline{\mathbf{S}}_{\text{ref}}\right).$$

  Possiamo stimare un valore p Monte Carlo:

  $$p_{\text{MC}} = \frac{1 + \sum_{j=1}^{M} \mathbb{1}(D_j \geq D_{\text{obs}})}{M+1}.$$

Questa costruzione verifica se lo scostamento della serie reale dalle statistiche tipiche del modello sia anomalo rispetto agli scostamenti osservati nelle simulazioni. Le simulazioni del test devono avere la stessa lunghezza temporale della serie reale di verifica. Inoltre, il modello e i pesi devono essere già fissati: usare per la verifica finale i dati sui quali abbiamo ottimizzato i parametri renderebbe il test eccessivamente favorevole. Un valore p_{MC} piccolo suggerisce che il modello non sia compatibile con l'insieme delle statistiche selezionate. Un valore non piccolo indica che non abbiamo evidenza sufficiente per respingerlo, non che abbiamo dimostrato che il modello sia vero.

2.6 Modifiche necessarie al modello NetLogo

Prima di eseguire tutte queste simulazioni, però, dobbiamo affrontare alcune criticità strutturali. La più importante è la coerenza tra prezzo, volume e operazioni realmente eseguite. Attualmente gli acquisti e le vendite aggiornano i portafogli individuali senza un esplicito meccanismo di abbinamento tra ordini. Questo significa che le quantità totali di Bitcoin e liquidità detenute dagli agenti possono cambiare anche in assenza di trasferimenti con una controparte identificata. Per un modello completamente endogeno dovremmo introdurre un meccanismo di scambio coerente, scegliendo tra un sistema di matching degli ordini e un market maker esplicito. Inoltre, occorre distinguere tra volume scambiato e pressione direzionale. In ogni scambio eseguito esistono sia un compratore sia un venditore: per definire uno sbilanciamento utile alla formazione del prezzo dobbiamo considerare, per esempio, il flusso di ordini aggressivi con segno, oppure la domanda e l'offerta immesse prima del matching. Rivedrei anche il ciclo temporale: le decisioni e gli ordini degli agenti dovrebbero contribuire alla formazione del prezzo successivo, anziché aggiornare il prezzo prima delle operazioni dello stesso passo temporale. Infine, per una versione completamente endogena, elimineremo il meccanismo che copia il prezzo reale durante la Fase 1. I dati reali serviranno alla calibrazione e alla validazione, non come forzante durante la generazione autonoma delle traiettorie. Dovremo anche verificare i fattori correttivi aggregati, come quello basato sull'ATH, per evitare che mascherino un comportamento che gli agenti non generano realmente.

2.7 Protocollo da seguire

Aspetto	**Scelta iniziale**
Frequenza	Giornaliera
Statistiche-obiettivo	8
Parametri da calibrare	Circa 5–6
Simulazioni per esplorazione iniziale	30–50 per configurazione
Simulazioni per raffinamento	100–200 per configurazione
Simulazioni finali di validazione	Almeno 500, se il costo computazionale lo permette
Stima incertezza empirica	*Stationary/block bootstrap*
Test principale	Compatibilità Monte Carlo congiunta
Test diagnostici	Ljung–Box, ARCH–LM, autocorrelazioni e distribuzioni empiriche

Tabella 6: Scelte iniziali per la procedura di calibrazione e validazione.

Riprodurre le statistiche finanziarie e dimostrare che il flocking ne è responsabile sono due risultati diversi. Se il modello completo riproduce le otto statistiche, abbiamo evidenza della sua adeguatezza rispetto a quell'insieme di proprietà empiriche. Se però otteniamo gli stessi risultati anche disattivando il flocking, allora il flocking non è necessario per spiegarle, almeno nell'ambito delle configurazioni studiate. Viceversa, se l'introduzione del flocking migliora sistematicamente la riproduzione del clustering della volatilità, della persistenza dei volumi o delle correlazioni prezzo-volume, avremo individuato un possibile meccanismo microscopico responsabile di proprietà macroscopiche. Questa, secondo me, è la domanda scientifica più interessante da porre nel vostro articolo: Quali meccanismi collettivi sono necessari, all'interno di un mercato artificiale minimale, per generare le proprietà statistiche osservate in un mercato reale come Bitcoin?